
Relatório Técnico

Tech Challenge Fase 2

Otimização de Modelos de Diagnóstico para Saúde da Mulher
via Algoritmo Genético + LLM

Aluno: **Guilherme Vieira Domingues**

Instituição: **FIAP — Pós Tech**

Fase: **2 — Evolução da IA: GenAI, Cloud ML e LLMs**

Projeto: **Projeto 1 — Otimização de Modelos de Diagnóstico**

Dataset: **Breast Cancer Wisconsin (UCI)**

Repositório: **github.com/GuilhermeVieira-code/FIAP_Tech_Challenge_Fase1_LR_CancerDeMama**

Vídeo: **<https://youtu.be/-J68ewiP3yl>**

Data: **Março 2026**

1. Introdução e Contexto

O objetivo deste projeto é otimizar automaticamente os hiperparâmetros do modelo de diagnóstico de câncer de mama desenvolvido na Fase 1, utilizando Algoritmo Genético (AG). Adicionalmente, integramos um LLM local (flan-t5-base) para transformar os resultados numéricos em linguagem clínica acessível aos profissionais de saúde.

O modelo da Fase 1 utilizava Regressão Logística com hiperparâmetros definidos manualmente:

- Scaler: RobustScaler
- PCA: 90% de variância
- C: 1.0 (regularização padrão)
- Solver: lbfgs

A hipótese central é que o AG pode encontrar uma combinação superior de hiperparâmetros ao explorar o espaço de busca de forma inteligente, sem a necessidade de grid search exaustivo.

2. Implementação do Algoritmo Genético

2.1 Representação dos Genes (Cromossomo)

Adotamos codificação real (real-valued encoding): cada indivíduo é um vetor de 6 genes reais em [0, 1].

Gene	Hiperparâmetro	Mapeamento
0	Scaler	Categórico: StandardScaler / RobustScaler / MinMaxScaler
1	Usar PCA	Binário: >= 0.5 = True
2	PCA variance	Contínuo: 0.80 - 0.99
3	C (LogReg)	Log-escala: 10^(-3 a +2) = 0.001 a 100
4	Solver	Categórico: lbfgs / liblinear / saga
5	max_iter	Inteiro: 200 - 2000

Justificativa: A codificação real é superior à binária para hiperparâmetros contínuos como C, que varia em ordens de magnitude. O crossover e a mutação operam diretamente nos valores reais, permitindo refinamento fino do espaço de busca.

2.2 Função Fitness

fitness = 0.45 x Recall + 0.25 x F1-score + 0.20 x Specificity + 0.10 x Equity

Justificativa dos pesos:

- Recall (45%): No contexto oncológico, falsos negativos (câncer não detectado) são clinicamente mais graves que falsos positivos. Uma paciente com diagnóstico perdido pode perder a janela de tratamento curativo.
- F1-score (25%): Garante equilíbrio geral entre precision e recall, evitando que o modelo maximize recall às custas de specificity extremamente baixa.
- Specificity (20%): Controla os falsos positivos — pacientes saudáveis diagnosticadas erroneamente geram ansiedade, biópsias desnecessárias e sobrecarga do sistema de saúde.

- Equity (10%): Mede a consistência do recall entre grupos demográficos (quartis de mean radius). Um modelo equitativo tem desempenho consistente independentemente do perfil da paciente.

A avaliação utiliza stratified k-fold cross-validation (5 folds) para garantir generalização.

2.3 Operadores Genéticos

Tournament Selection (k=3):

Escolhido porque nossa população converge rápido — todos ficam com fitness entre 0.96 e 0.98. O torneio cria pressão seletiva mesmo quando as diferenças são mínimas, sem depender de escala absoluta dos valores.

Uniform Crossover + Arithmetic Crossover (alternados):

Usamos os dois juntos: o Uniform embaralha genes categóricos independentes (Scaler, Solver), enquanto o Arithmetic gera valores intermediários para genes contínuos como C e PCA variance — mais eficiente que escolher só um dos dois.

Gaussian Mutation:

Perfeita para espaço contínuo: faz pequenas perturbações ao redor do valor atual em vez de saltar aleatoriamente. Isso permite refinamento fino sem desfazer o progresso já conquistado pelas gerações anteriores.

Elitism (top 2):

Garante que o melhor modelo nunca se perde entre gerações. Sem elitismo, um crossover azarado poderia descartar a melhor solução encontrada.

3. Experimentos Realizados

Foram realizados 3 experimentos com diferentes configurações do AG:

Experimento	Pop	Mutation Rate	Gerações	Objetivo
Exp 1	30	0.15	20	Fast convergence (baseline de comparação)
Exp 2	50	0.10	30	Equilíbrio exploration/exploitation
Exp 3	80	0.20	30	Alta diversidade — maior exploration do espaço

3.1 Resultados por Experimento

Experimento	Fitness Final	Tempo	Hiperparâmetros Ótimos
Exp 1	0.9707	27.8s	StandardScaler sem PCA C=0.0961 lbfgs
Exp 2	0.9714	65.9s	StandardScaler sem PCA C=0.1673 liblinear
Exp 3 (VENCEDOR)	0.9730	157.4s	StandardScaler PCA(0.98) C=0.2706 lbfgs

3.2 Análise dos Experimentos

O Experimento 3 obteve o melhor fitness por dois fatores:

1. Larger population (80): Maior diversidade genética inicial, reduzindo o risco de premature convergence em ótimos locais.

2. Higher mutation rate (0.20): Maior capacidade de exploration — o AG conseguiu escapar de regiões subótimas onde os experimentos menores ficaram presos.

O trade-off é o tempo de execução (157s vs 27s do Exp 1), aceitável para um processo de otimização periódica offline.




Figura 1 — Curvas de Convergência dos 3 Experimentos do Algoritmo Genético

4. Comparativo de Desempenho

Avaliação no conjunto de teste (20% dos dados, 114 pacientes):

Métrica	Baseline (Fase 1)	Otimizado (AG — Exp 3)	Melhoria
Recall	0.9524	0.9762	+0.0238
F1-score	0.9524	0.9762	+0.0238
Accuracy	0.9649	0.9825	+0.0176
Specificity	—	0.9861	—
Precision (Maligno)	0.95	0.98	+0.03
Precision (Benigno)	0.97	0.99	+0.02




Figura 2 — Comparativo de Métricas: Baseline (Fase 1) vs Modelo Otimizado (Exp 3)

4.1 Descobertas do AG

Hiperparâmetro	Fase 1	AG encontrou	Interpretação
Scaler	RobustScaler	StandardScaler	Dataset não tem outliers extremos que justifiquem RobustScaler
PCA	90% variância	98% variância	Manter mais componentes preserva informação diagnóstica
C	1.0	0.27	Regularização mais forte — modelo Fase 1 estava sub-regularizado
Solver	lbfgs	lbfgs	Correto para regularização L2 — AG confirmou

4.2 Impacto Clínico

A melhoria de +0.0238 no recall significa que, em um conjunto de 42 pacientes malignas (como no conjunto de teste), o modelo otimizado detecta 1 caso a mais que passaria despercebido pelo modelo original. Em escala hospitalar de 1.000 pacientes/mês, isso representa aproximadamente 24 mulheres diagnosticadas a mais por mês.

4.3 Análise de Equidade Demográfica

A métrica de Equity na função fitness avalia a consistência do recall entre diferentes subgrupos de pacientes, estratificados por quartis de mean_radius (proxy demográfico). O modelo otimizado apresenta recall consistente entre os 4 quartis, indicando que a melhoria na detecção beneficia igualmente pacientes com diferentes perfis tumorais — um requisito crítico para equidade no diagnóstico oncológico feminino.

5. Integração com LLM

5.1 Modelo Escolhido

google/flan-t5-base — modelo seq2seq de 250M parâmetros (~990 MB), executado 100% localmente sem necessidade de API ou internet após o primeiro download.

Justificativa da escolha local:

- Privacidade: Dados de pacientes não saem da instituição
- Custo zero: Sem dependência de APIs pagas
- Disponibilidade: Funciona offline — hospitais não podem depender de internet

5.2 Técnicas de Prompt Engineering

Todos os prompts foram projetados com 3 princípios:

- Contexto médico feminino: especialização em oncologia mamária
- Sensibilidade de gênero: linguagem empática e acolhedora
- Privacidade: nenhum dado identificável é enviado ao modelo

Os prompts foram otimizados para o modelo flan-t5 (seq2seq), usando instruções curtas e diretas que maximizam a qualidade da geração. Um sistema de fallback baseado em templates estruturados garante respostas úteis mesmo quando o modelo não gera texto adequado.

Exemplo de prompt utilizado (explicação de diagnóstico):

"Medical diagnosis report for breast cancer. Result: malignant. Confidence: 87%. Recall: 97.6%. Write clinical explanation in Portuguese."

5.3 Outputs Gerados pelo LLM

Output	Público-alvo	Conteúdo
explicacao_diagnostico.txt	Médico / Paciente	Resultado, confiança, próximos passos clínicos
comparacao_modelos.txt	Gestão hospitalar	Impacto clínico da melhoria, recomendação de adoção
analise_experimentos.txt	Time técnico	Melhor configuração do AG, análise comparativa

5.4 Avaliação de Qualidade das Respostas LLM

Cada resposta é avaliada automaticamente em 4 critérios:

Critério	Peso	Métrica
Completeness	30%	Mínimo de 150 palavras
Medical Terminology	40%	Presença de termos clínicos relevantes
Adequacy	20%	Ausência de linguagem alarmista
Language (PT-BR)	10%	Marcadores do português brasileiro

As respostas avaliadas como "Boa" (score >= 0.7) são salvas em llm_responses/*.json no formato prompt+resposta, constituindo o dataset inicial para fine-tuning na Fase 3.

6. Arquitetura da Solução

O sistema é composto por 3 módulos principais:

genetic_algorithm.py — Motor do AG

Cromossomo com 6 genes reais [0,1] | Avaliação por stratified k-fold CV (5 folds) | Operadores: Tournament Selection, Uniform/Arithmetic Crossover, Gaussian Mutation, Elitism

llm.py — Módulo LLM Local

Pipeline flan-t5-base (Hugging Face Transformers) | Detecção de echo + fallback estruturado | Avaliação automática de qualidade | Persistência das respostas para Fase 3

main.py — Pipeline de Orquestração

Carregamento de dados, avaliação baseline, execução dos 3 experimentos | Geração de gráficos (convergence.png, metrics_comparison.png) | Exportação de resultados em JSON

Fluxo do Pipeline:

breast_cancer_dataset.csv -> load_data() -> Algoritmo Genético (3 experimentos) -> Avaliação no conjunto de teste -> LLM Local (flan-t5-base) -> llm_responses/*.json (dataset para Fase 3)

7. Escalabilidade e Monitoramento

O sistema foi projetado para execução periódica offline, sem necessidade de infraestrutura em nuvem:

- Cache de dados: O dataset é carregado uma única vez em memória
- Singleton do modelo LLM: O pipeline flan-t5 é inicializado uma vez e reutilizado
- Parâmetros configuráveis via CLI: --cv-folds permite balancear velocidade vs. precisão
- Logs estruturados: Todos os resultados são salvos em JSON para auditoria e reprodutibilidade (experiment_results.json, llm_responses/*.json)

8. Considerações Éticas

- Privacidade: Nenhum dado identificável de pacientes é utilizado ou transmitido. O LLM roda 100% local.
- Equidade: A função fitness inclui explicitamente uma métrica de equidade demográfica (10% do peso), penalizando modelos com desempenho inconsistente entre subgrupos.
- Viés (Bias): O uso de stratified k-fold garante representação proporcional de classes maligno/benigno em todos os folds de avaliação.
- Responsabilidade: O sistema é explicitamente apresentado como ferramenta de apoio à decisão — a decisão diagnóstica final é sempre do médico.
- Transparência: Todas as decisões de design, pesos da fitness e limitações do modelo são documentadas.
- LGPD: Os dados sintéticos/anônimos do dataset Wisconsin (UCI) não contêm informações pessoais identificáveis.

9. Contribuição para a Fase 3

Os arquivos em llm_responses/*.json contêm pares (prompt, resposta) com score de qualidade automático, constituindo o dataset inicial para fine-tuning de um LLM especializado em saúde feminina na Fase 3. O contexto médico feminino estabelecido nos prompts desta Fase 2 será diretamente reutilizado como base para o assistente médico completo.

10. Conclusão

O Algoritmo Genético demonstrou eficácia na otimização de hiperparâmetros do modelo de diagnóstico de câncer de mama, superando o modelo original em todas as métricas relevantes. A melhoria de +2.38% no recall tem impacto clínico direto: aproximadamente 24 mulheres diagnosticadas a mais por mês em escala hospitalar.

A integração com LLM local (flan-t5-base) resolve o problema de comunicabilidade dos resultados, tornando o sistema utilizável por profissionais de saúde sem background técnico em ML, com total privacidade dos dados da paciente.