
Relatorio Tecnico

Tech Challenge Fase 2

Otimizacao de Modelos de Diagnostico para Saude da Mulher
via Algoritmo Genetico + LLM

Instituicao:	FIAP - Pos Tech
Fase:	2 - Algoritmos Geneticos e LLMs
Projeto:	Projeto 1 - Otimizacao de Modelos de Diagnostico
Dataset:	Breast Cancer Wisconsin (UCI)
Data:	Marco 2026

1. Introducao e Contexto

O objetivo deste projeto e otimizar automaticamente os hiperparametros do modelo de diagnostico de cancer de mama desenvolvido na Fase 1, utilizando Algoritmo Genetico (AG). Adicionalmente, integramos um LLM local (flan-t5-base) para transformar os resultados numericos em linguagem clinica acessivel aos profissionais de saude.

O modelo da Fase 1 utilizava Regressao Logistica com hiperparametros definidos manualmente:

- Scaler: RobustScaler
- PCA: 90% de variancia
- C: 1.0 (regularizacao padrao)
- Solver: lbfgs

A hipotese central e que o AG pode encontrar uma combinacao superior de hiperparametros ao explorar o espaco de busca de forma inteligente, sem a necessidade de grid search exaustivo.

2. Implementacao do Algoritmo Genetico

2.1 Representacao dos Genes (Cromossomo)

Adotamos codificacao real (real-valued encoding): cada individuo e um vetor de 6 genes reais em [0, 1].

Gene	Hiperparametro	Mapeamento
0	Scaler	Categorico: StandardScaler / RobustScaler / MinMaxScaler
1	Usar PCA	Binario: ≥ 0.5 = True
2	PCA variance	Continuo: 0.80 - 0.99
3	C (LogReg)	Log-escala: $10^{(-3 \text{ a } +2)}$ = 0.001 a 100
4	Solver	Categorico: lbfgs / liblinear / saga
5	max_iter	Inteiro: 200 - 2000

Justificativa: A codificacao real e superior a binaria para hiperparametros continuos como C, que varia em ordens de magnitude. O crossover e a mutacao operam diretamente nos valores reais, permitindo refinamento fino do espaco de busca.

2.2 Funcao Fitness

$$\text{fitness} = 0.45 \times \text{Recall} + 0.25 \times \text{F1-score} + 0.20 \times \text{Specificity} + 0.10 \times \text{Equity}$$

Justificativa dos pesos:

- **Recall (45%)**: No contexto oncologico, false negatives (cancer nao detectado) sao clinicamente mais graves que false positives. Uma paciente com diagnostico perdido pode perder a janela de tratamento curativo.
- **F1-score (25%)**: Garante equilibrio geral entre precision e recall, evitando que o modelo maximize recall as custas de specificity extremamente baixa.
- **Specificity (20%)**: Controla os false positives - pacientes saudaveis diagnosticadas erroneamente geram ansiedade, biopsias desnecessarias e sobrecarga do sistema de saude.

- **Equity (10%):** Mede a consistencia do recall entre grupos demograficos (quartis de mean radius). Um modelo equitativo tem desempenho consistente independentemente do perfil da paciente.

A avaliacao utiliza stratified k-fold cross-validation (5 folds) para garantir generalizacao.

2.3 Operadores Geneticos

Selection - Tournament Selection (k=3):

Tres individuos sao sorteados aleatoriamente; o de maior fitness e selecionado para reproducao. Cria pressao seletiva consistente independente da escala absoluta dos valores de fitness - essencial quando a populacao ja esta bem convergida (fitness entre 0.96 e 0.98).

Crossover - Uniform e Arithmetic (alternados):

Uniform Crossover: cada gene e herdado de um dos pais com probabilidade 0.5. Adequado para genes independentes. Arithmetic Crossover: filho = alpha x pai1 + (1-alpha) x pai2, com alpha entre 0.3 e 0.7. Ideal para genes continuos (C, PCA variance), gerando filhos com valores intermediarios.

Mutation - Gaussian Mutation:

Cada gene sofre perturbacao N(0, sigma) com probabilidade mutation_rate. A distribuicao gaussiana realiza pequenas perturbacoes ao redor do valor atual, ideal para refinamento fino. Apos a perturbacao, os genes sao recortados em [0, 1].

Elitism:

Os 2 melhores individuos de cada geracao passam diretamente para a proxima, garantindo que o melhor modelo encontrado nunca seja perdido.

3. Experimentos Realizados

Foram realizados 3 experimentos com diferentes configuracoes do AG:

Experimento	Pop	Mutation Rate	Geracoes	Objetivo
Exp 1	30	0.15	20	Fast convergence (comparison baseline)
Exp 2	50	0.10	30	Exploration/exploitation balance
Exp 3	80	0.20	30	High diversity - maior exploration do espaco

3.1 Resultados por Experimento

Experimento	Fitness Final	Tempo	Hiperparametros Otimos
Exp 1	0.9707	27.8s	StandardScaler sem PCA C=0.0961 lbfgs
Exp 2	0.9714	65.9s	StandardScaler sem PCA C=0.1673 liblinear
Exp 3 (VENCEDOR)	0.9730	157.4s	StandardScaler PCA(0.98) C=0.2706 lbfgs

3.2 Analise dos Experimentos

O Experimento 3 obteve o melhor fitness por dois fatores:

1. Larger population (80): Maior genetic diversity inicial, reduzindo o risco de premature convergence em local optima.

2. Higher mutation rate (0.20): Maior capacidade de exploration - o AG conseguiu sair de regioes subotimas onde os experimentos menores ficaram presos.

O trade-off e o tempo de execucao (157s vs 27s do Exp 1), aceitavel para um processo de otimizacao periodica offline.




Figura 1 - Curvas de Convergencia dos 3 Experimentos do Algoritmo Genetico

4. Comparativo de Desempenho

Avaliacao no conjunto de teste (20% dos dados, 114 pacientes):

Metrica	Baseline (Fase 1)	Otimizado (AG - Exp 3)	Melhoria
Recall	0.9524	0.9762	+0.0238
F1-score	0.9524	0.9762	+0.0238
Accuracy	0.9649	0.9825	+0.0176
Specificity	-	0.9861	-
Precision (Malignant)	0.95	0.98	+0.03
Precision (Benign)	0.97	0.99	+0.02




Figura 2 - Comparativo de Metricas: Baseline (Fase 1) vs Modelo Otimizado (Exp 3)

4.1 Descobertas do AG

Hiperparametr o	Fase 1	AG encontrou	Interpretacao
Scaler	RobustScaler	StandardScaler	Dataset nao tem outliers extremos que justifiquem RobustScaler
PCA	90% variancia	98% variancia	Manter mais componentes preserva informacao diagnostica
C	1.0	0.27	Regularizacao mais forte - modelo Fase 1 estava sub-regularizado
Solver	lbfgs	lbfgs	Correto para regularizacao L2 - AG confirmou

4.2 Impacto Clinico

A melhoria de +0.0238 no recall significa que, em um conjunto de 42 pacientes malignas (como no conjunto de teste), o modelo otimizado detecta 1 caso a mais que passaria despercebido pelo modelo original. Em escala hospitalar de 1.000 pacientes/mes, isso representa aproximadamente 24 mulheres diagnosticadas a mais por mes.

4.3 Analise de Equidade Demografica

A metrica de Equity na funcao fitness avalia a consistencia do recall entre diferentes subgrupos de pacientes, estratificados por quartis de mean_radius (proxy demografico). O modelo otimizado apresenta recall consistente entre os 4 quartis, indicando que a melhoria na deteccao beneficia igualmente pacientes com diferentes perfis tumorais - um requisito critico para equidade no diagnostico oncologico feminino.

5. Integracao com LLM

5.1 Modelo Escolhido

google/flan-t5-base - modelo seq2seq de 250M parametros (~990 MB), executado 100% localmente sem necessidade de API ou internet apos o primeiro download.

Justificativa da escolha local:

- Privacidade: Dados de pacientes nao saem da instituicao
- Custo zero: Sem dependencia de APIs pagas
- Disponibilidade: Funciona offline - hospitais nao podem depender de internet

5.2 Tecnicas de Prompt Engineering

Todos os prompts foram projetados com 3 principios:

- Contexto medico feminino: especializacao em oncologia mamaria
- Sensibilidade de genero: linguagem empatica e acolhedora
- Privacidade: nenhum dado identificavel e enviado ao modelo

Os prompts foram otimizados para o modelo flan-t5 (seq2seq), usando instrucoes curtas e diretas que maximizam a qualidade da geracao. Um sistema de fallback baseado em templates estruturados garante respostas uteis mesmo quando o modelo nao gera texto adequado.

Exemplo de prompt utilizado (explicacao de diagnostico):

"Medical diagnosis report for breast cancer. Result: malignant. Confidence: 87%. Recall: 97.6%. Write clinical explanation in Portuguese."

5.3 Outputs Gerados pelo LLM

Output	Publico-alvo	Conteudo
explicacao_diagnostico.txt	Medico / Paciente	Resultado, confianca, proximos passos clinicos
comparacao_modelos.txt	Gestao hospitalar	Impacto clinico da melhoria, recomendacao de adocao
analise_experimentos.txt	Time tecnico	Melhor configuracao do AG, analise comparativa

5.4 Avaliacao de Qualidade das Respostas LLM

Cada resposta e avaliada automaticamente em 4 criterios:

Criterio	Peso	Metrica
Completeness	30%	Minimo de 150 palavras
Medical Terminology	40%	Presenca de termos clinicos relevantes
Adequacy	20%	Ausencia de linguagem alarmista
Language (PT-BR)	10%	Marcadores do portugues brasileiro

As respostas avaliadas como "Boa" (score ≥ 0.7) sao salvas em `llm_responses/*.json` no formato `prompt+resposta`, constituindo o dataset inicial para fine-tuning na Fase 3.

6. Arquitetura da Solucao

O sistema e composto por 3 modulos principais:

genetic_algorithm.py - Motor do AG

Cromossomo com 6 genes reais [0,1] | Avaliacao por stratified k-fold CV (5 folds) | Operadores: Tournament Selection, Uniform/Arithmetic Crossover, Gaussian Mutation, Elitism

llm.py - Modulo LLM Local

Pipeline `flan-t5-base` (Hugging Face Transformers) | Deteccao de echo + fallback estruturado | Avaliacao automatica de qualidade | Persistencia das respostas para Fase 3

main.py - Pipeline de Orquestracao

Carregamento de dados, avaliacao baseline, execucao dos 3 experimentos | Geracao de graficos (`convergence.png`, `metrics_comparison.png`) | Exportacao de resultados em JSON

Fluxo do Pipeline:

`breast_cancer_dataset.csv` -> `load_data()` -> Algoritmo Genetico (3 experimentos) -> Avaliacao no conjunto de teste -> LLM Local (`flan-t5-base`) -> `llm_responses/*.json` (dataset para Fase 3)

7. Escalabilidade e Monitoramento

O sistema foi projetado para execucao periodica offline, sem necessidade de infraestrutura em nuvem:

- Cache de dados: O dataset e carregado uma unica vez em memoria
- Singleton do modelo LLM: O pipeline flan-t5 e inicializado uma vez e reutilizado
- Parametros configuráveis via CLI: --cv-folds permite balancear velocidade vs. precisao
- Logs estruturados: Todos os resultados sao salvos em JSON para auditoria e reproducibilidade (experiment_results.json, llm_responses/*.json)

8. Desafios e Solucoes

Desafio	Solucao Implementada
Espaco em disco limitado para PyTorch	Instalacao CPU-only (--index-url .../whl/cpu)
flan-t5 ecoando prompts longos	Prompts mais curtos + deteccao de echo (_is_echo()) + fallback com templates
Avaliacao de equidade sem dados demograficos	Proxy por quartis de mean_radius (feature 0 do dataset)
Tempo de avaliacao do AG elevado	--cv-folds 3 para desenvolvimento; 5 folds para resultados finais
Hiperparametros em escalas muito diferentes	Log-escala para C (0.001 a 100); codificacao real normalizada [0,1]

9. Consideracoes Eticas

- **Privacidade:** Nenhum dado identificavel de pacientes e utilizado ou transmitido. O LLM roda 100% local.
- **Equidade:** A funcao fitness inclui explicitamente uma metrica de equidade demografica (10% do peso), penalizando modelos com desempenho inconsistente entre subgrupos.
- **Vies (Bias):** O uso de stratified k-fold garante representacao proporcional de classes maligno/benigno em todos os folds de avaliacao.
- **Responsabilidade:** O sistema e explicitamente apresentado como ferramenta de apoio a decisao - a decisao diagnostica final e sempre do medico.
- **Transparencia:** Todas as decisoes de design, pesos da fitness e limitacoes do modelo sao documentadas.
- **LGPD:** Os dados sinteticos/anonimos do dataset Wisconsin (UCI) nao contem informacoes pessoais identificaveis.

10. Contribuicao para a Fase 3

Os arquivos em llm_responses/*.json contem pares (prompt, resposta) com score de qualidade automatico, constituindo o dataset inicial para fine-tuning de um LLM especializado em saude feminina na Fase 3. O contexto medico feminino estabelecido nos prompts desta Fase 2 sera diretamente reutilizado como base para o assistente medico completo.

11. Conclusao

O Algoritmo Genetico demonstrou eficacia na otimizacao de hiperparametros do modelo de diagnostico de cancer de mama, superando o modelo original em todas as metricas relevantes. A melhoria de +2.38% no recall tem impacto clinico direto: aproximadamente 24 mulheres diagnosticadas a mais por mes em escala

hospitalar.

A integracao com LLM local (flan-t5-base) resolve o problema de comunicabilidade dos resultados, tornando o sistema utilizavel por profissionais de saude sem background tecnico em ML, com total privacidade dos dados da paciente.

O projeto atende integralmente aos requisitos do Tech Challenge Fase 2 - Projeto 1, incluindo: codificacao de genes, operadores geneticos, funcao fitness clinica com equidade, 3 experimentos comparativos, integracao LLM sensivel ao genero, avaliacao de qualidade das respostas e preparacao do dataset para a Fase 3.