

TECH CHALLENGE - FASE 1

Sistema de Suporte ao Diagnóstico de Câncer de Mama

Relatório Técnico

RESUMO EXECUTIVO

***Nota:** Todos os valores numéricos e resultados apresentados neste relatório podem ser verificados e reproduzidos através dos notebooks `01_ed.ipynb` e `02_preprocessing_and_modeling.ipynb` disponíveis no repositório do projeto.*

Este relatório apresenta o desenvolvimento de um sistema de Machine Learning para auxiliar no diagnóstico de câncer de mama, classificando tumores como benignos ou malignos a partir de dados clínicos estruturados. O projeto utilizou o Breast Cancer Wisconsin Dataset, contendo 569 registros com 30 características extraídas de exames de imagem.

O modelo final selecionado foi uma Regressão Logística combinada com RobustScaler e PCA (redução de dimensionalidade mantendo 90% da variância), alcançando accuracy de 0.982456 e recall de 0.952381 na classe maligna. Este desempenho indica alta capacidade de identificar casos malignos, minimizando falsos negativos, métrica crítica em contextos médicos.

O sistema demonstra potencial como ferramenta de suporte à decisão clínica, mas requer validações adicionais, testes em cenários reais e aprovação regulatória antes de aplicação em ambiente hospitalar.

1. INTRODUÇÃO

1.1 Contexto e Motivação

O câncer de mama representa um dos principais desafios de saúde pública mundial, sendo uma das neoplasias malignas mais comuns entre mulheres. O diagnóstico precoce é fundamental para aumentar as chances de tratamento bem-sucedido e reduzir a mortalidade.

Hospitais universitários enfrentam volume crescente de pacientes e exames, gerando demanda por sistemas inteligentes que possam auxiliar na triagem inicial e otimizar o tempo dos profissionais de saúde. Neste contexto, técnicas de Machine Learning podem processar grandes volumes de dados médicos e fornecer suporte objetivo às decisões clínicas.

1.2 Objetivo do Projeto

Desenvolver um sistema de classificação binária baseado em Machine Learning capaz de distinguir tumores benignos de malignos a partir de características extraídas de exames de imagem, priorizando a redução de falsos negativos (alta sensibilidade/recall).

1.3 Dataset Utilizado

Fonte: Breast Cancer Wisconsin Dataset (disponível no Kaggle)

Tamanho: 569 registros

Features: 30 variáveis numéricas

Target: Diagnóstico (B = Benigno, M = Maligno)

Distribuição: 357 benignos (62.74%) | 212 malignos (37.26%)

As features incluem medidas como raio, textura, perímetro, área, suavidade, compacidade e concavidade, calculadas em três níveis: média (mean), erro padrão (se) e pior caso (worst).

2. ANÁLISE EXPLORATÓRIA DE DADOS (EDA)

2.1 Estrutura dos Dados

A análise inicial revelou um dataset bem estruturado, contendo 569 registros e 33 colunas (incluindo identificador e target). As principais características identificadas foram:

- **Tipos de dados:** Predominantemente float64 (variáveis numéricas contínuas) e object para a variável target
- **Valores ausentes:** Nenhum valor missing identificado
- **Colunas irrelevantes:** 'id' (identificador) e 'Unnamed: 32' (coluna vazia)

2.2 Estatísticas Descritivas

A análise estatística descritiva evidenciou:

- **Escala muito distintas:** Variáveis com magnitudes diferentes (ex: radius_mean ~ 14.13 vs area_mean ~ 654.89), indicando necessidade de padronização
- **Presença de outliers:** Valores extremos identificados em diversas variáveis
- **Distribuições assimétricas:** Algumas features apresentam assimetria positiva

2.3 Análise da Variável Target

A distribuição da variável alvo mostrou leve desbalanceamento:

- **Classe Benigna (B):** 357 casos (62.74%)
- **Classe Maligna (M):** 212 casos (37.26%)

Este desbalanceamento foi considerado na etapa de modelagem através do uso de estratificação na divisão treino/teste.

2.4 Análise de Correlação

A matriz de correlação revelou forte multicolinearidade entre variáveis relacionadas ao tamanho do tumor:

- **Alta correlação:** Entre radius, perimeter e area (tanto nas versões mean quanto worst)
- **Redundância de informação:** Grupos de features altamente correlacionadas
- **Implicação:** Justifica o uso de técnicas de redução de dimensionalidade (PCA)

3. ESTRATÉGIAS DE PRÉ-PROCESSAMENTO

3.1 Limpeza de Dados

Remoção de colunas irrelevantes:

- Coluna 'id': Identificador único sem valor preditivo
- Coluna 'Unnamed: 32': Coluna completamente vazia

Estas colunas foram removidas para evitar ruído no modelo e reduzir dimensionalidade desnecessária.

3.2 Codificação da Variável Target

A variável target categórica foi convertida para formato numérico:

- **B (Benigno)** → 0
- **M (Maligno)** → 1

Esta codificação permite o uso em algoritmos de classificação supervisionada.

3.3 Divisão Treino/Teste

Divisão estratificada para manter proporção das classes:

- **Proporção:** 80% treino / 20% teste (test_size=0.2)
- **Conjunto de treino:** 455 amostras
- **Conjunto de teste:** 114 amostras
- **Estratificação:** Mantém proporção 62.74% / 37.26% em ambos os conjuntos
- **Random state:** 42 (reprodutibilidade)

3.4 Padronização (Feature Scaling)

Devido às escalas distintas entre variáveis, foram testadas duas abordagens de padronização (feature scaling):

StandardScaler:

- Transforma features para média 0 e desvio padrão 1
- Fórmula: $z = (x - \mu) / \sigma$
- Sensível a outliers
- Usado em modelos baseline

RobustScaler (escolhido no modelo final):

- Usa mediana e intervalo interquartil (IQR)
- Fórmula: $z = (x - \text{mediana}) / \text{IQR}$
- Robusto a outliers (mais adequado para este dataset)
- Melhor desempenho em combinação com PCA

3.5 Redução de Dimensionalidade (PCA)

Aplicação de PCA (Principal Component Analysis) para lidar com multicolinearidade e reduzir dimensionalidade:

- **Variância explicada:** 90% (retém 90% da informação original)
- **Processo de seleção:** Foram testadas diferentes configurações de variância explicada. A

configuração de 90% foi selecionada por apresentar o melhor equilíbrio entre redução de dimensionalidade e preservação de informação relevante, resultando no melhor desempenho nos testes de validação.

- **Benefícios:** Reduz redundância, remove correlações, melhora generalização
- **Trade-off:** Perda de interpretabilidade individual das features originais

4. MODELOS UTILIZADOS E JUSTIFICATIVAS

4.1 Critérios de Seleção

A seleção dos algoritmos foi baseada no conteúdo abordado no curso sobre classificação binária. Os três modelos escolhidos são adequados para o problema de classificação de duas classes e permitiram comparação de diferentes abordagens (linear, ensemble e margem máxima).

Métricas priorizadas na avaliação:

- **Recall (Sensibilidade):** Minimizar falsos negativos em contexto médico
- **F1-Score:** Equilíbrio entre precisão e recall
- **Accuracy:** Desempenho geral do modelo

4.2 Algoritmos Testados

Regressão Logística: Selecionada como modelo principal após observação na aba Code do Kaggle, onde muitas soluções para este mesmo dataset utilizavam este algoritmo, indicando ser uma alternativa promissora. Modelo baseline adequado para classificação binária conforme abordado no curso.

Random Forest: Incluído para comparação com abordagem de ensemble. Permite avaliar se padrões não-lineares melhoram o desempenho e fornece feature importance para análise.

SVM (Support Vector Machine): Testado para comparação com abordagem baseada em margem máxima. Algoritmo adequado para classificação binária apresentado no curso.

5. RESULTADOS E INTERPRETAÇÃO

5.1 Comparação de Modelos

A tabela abaixo apresenta as métricas dos três melhores modelos testados:

Modelo	Accuracy	Recall	F1-Score
LogReg (RobustScaler + PCA 90%)	0.982456	0.952381	0.975610
Random Forest	0.973684	0.928571	0.962963
SVM (StandardScaler)	0.973684	0.928571	0.962963

5.2 Modelo Selecionado

Regressão Logística + RobustScaler + PCA (90% variância)

Métricas no conjunto de teste:

- **Accuracy:** 0.982456
- **Recall (classe maligna):** 0.952381
- **F1-Score:** 0.975610

Validação Cruzada (k-fold, k=5):

- **Recall médio:** 0.929412
- **Desvio padrão:** 0.060563
- **Interpretação:** Desempenho consistente em diferentes subconjuntos, variação moderada esperada em datasets médicos de volume limitado

5.3 Justificativa da Escolha

O modelo de Regressão Logística com RobustScaler e PCA foi selecionado pelos seguintes motivos:

1. **Melhor Recall:** 0.952381 vs 0.928571 dos demais (crítico para evitar falsos negativos)
2. **Melhor Accuracy:** 0.982456 vs 0.973684 dos concorrentes
3. **Robustez a outliers:** RobustScaler mais adequado que StandardScaler
4. **Redução de multicolinearidade:** PCA elimina redundância entre features
5. **Generalização:** Cross-validation demonstra consistência
6. **Interpretabilidade:** Modelo linear mais interpretável que Random Forest ou SVM

5.4 Interpretação dos Resultados

Alta capacidade preditiva: O modelo demonstra excelente capacidade de distinguir tumores benignos de malignos, com acurácia de 0.982456.

Minimização de falsos negativos: Com recall de 0.952381, o modelo identifica corretamente a grande maioria dos casos malignos. Em contexto médico, isto significa que poucos pacientes com câncer seriam classificados incorretamente como benignos.

Estabilidade: A validação cruzada (recall médio de 0.929412 com desvio padrão de 0.060563) confirma que o modelo mantém desempenho consistente em diferentes subconjuntos dos dados, indicando boa capacidade de generalização.

6. DISCUSSÃO CRÍTICA E APLICABILIDADE PRÁTICA

6.1 Potencial de Aplicação Clínica

O modelo desenvolvido apresenta resultados promissores e pode ser aplicado como:

- **Sistema de triagem inicial:** Priorizar casos suspeitos para avaliação médica urgente
- **Segunda opinião automatizada:** Fornecer análise adicional para apoiar decisão médica
- **Ferramenta educacional:** Treinar profissionais em padrões de diagnóstico
- **Análise retrospectiva:** Revisar casos históricos e identificar padrões

6.2 Limitações Identificadas

6.2.1 Limitações do Dataset

- **Tamanho limitado:** 569 amostras podem não capturar toda variabilidade populacional
- **Origem única:** Dados de uma única instituição (Wisconsin) podem ter viés geográfico ou demográfico
- **Características isoladas:** Não considera histórico clínico, idade, fatores de risco
- **Snapshot temporal:** Não avalia progressão temporal da doença

6.2.2 Limitações do Modelo

- **Perda de interpretabilidade:** PCA reduz capacidade de explicar contribuição individual de cada feature original
- **Falsos negativos remanescentes:** Modelo não detecta todos os casos malignos (recall = 0.952381)
- **Ausência de calibração probabilística:** Probabilidades preditas podem não refletir risco real
- **Validação em amostra única:** Não testado em população externa

6.3 Papel do Profissional Médico

IMPORTANTE: Este sistema deve ser compreendido estritamente como ferramenta de **suporte à decisão**, não como substituto do julgamento clínico.

O modelo NÃO substitui:

- Avaliação médica completa e contextualizada
- Exame físico e anamnese detalhada
- Consideração de histórico clínico e fatores de risco individuais
- Outros exames complementares (biópsia, mamografia, ultrassom)
- Experiência e intuição clínica do profissional

A decisão final sobre diagnóstico, conduta e tratamento **sempre** deve permanecer com o(a) médico(a), que possui visão holística do paciente e responsabilidade legal pelo cuidado prestado.

6.4 Requisitos para Uso em Produção

Antes de implementação em ambiente hospitalar real, seria necessário:

1. Validação Externa:

- Testar em datasets de diferentes hospitais e regiões geográficas
- Avaliar desempenho em diferentes grupos demográficos (idade, etnia, etc.)

- Validar em coortes prospectivas (dados coletados após desenvolvimento do modelo)

2. Análise de Viés e Equidade:

- Verificar se o modelo performa igualmente bem em todos os subgrupos populacionais
- Identificar e mitigar possíveis vieses algorítmicos
- Garantir equidade no acesso e qualidade do diagnóstico

3. Calibração Probabilística:

- Ajustar probabilidades preditas para refletir risco real
- Permitir que médicos tomem decisões baseadas em níveis de confiança calibrados

4. Explicabilidade (XAI):

- Implementar técnicas como SHAP ou LIME para explicar previsões individuais
- Permitir que médicos compreendam o raciocínio do modelo
- Aumentar confiança e adoção clínica

5. Monitoramento Contínuo:

- Sistema de detecção de data drift (mudança na distribuição dos dados)
- Monitoramento de degradação de performance ao longo do tempo
- Retreinamento periódico com novos dados

6. Aprovação Regulatória:

- Cumprir requisitos da ANVISA para dispositivos médicos
- Seguir normas internacionais (FDA, CE Mark) se aplicável
- Documentação completa de validação e testes clínicos

7. Integração com Sistema Hospitalar:

- Interface intuitiva para uso por profissionais de saúde
- Integração com prontuário eletrônico (PEP)
- Fluxo de trabalho que respeite autonomia médica

7. CONCLUSÃO

Este projeto desenvolveu com sucesso um sistema de Machine Learning para classificação de tumores de mama, alcançando accuracy de 0.982456 e recall de 0.952381 na identificação de casos malignos.

A metodologia aplicada incluiu análise exploratória criteriosa, estratégias robustas de pré-processamento (RobustScaler e PCA), e comparação sistemática de múltiplos algoritmos de classificação. O modelo final selecionado (Regressão Logística + RobustScaler + PCA) demonstrou o melhor equilíbrio entre desempenho, estabilidade e interpretabilidade.

Os resultados indicam que sistemas de IA têm potencial significativo como ferramentas de suporte ao diagnóstico médico. Contudo, é fundamental reconhecer as limitações atuais e os requisitos adicionais necessários antes de aplicação clínica real.

Principais contribuições do projeto:

1. Implementação de pipeline completo de Machine Learning para dados médicos
2. Comparação sistemática de técnicas de pré-processamento e modelagem
3. Priorização de métricas relevantes para contexto médico (Recall)
4. Discussão crítica sobre aplicabilidade e limitações
5. Código documentado e reproduzível via Docker

O projeto demonstra a viabilidade técnica de sistemas de IA para suporte ao diagnóstico de câncer de mama, estabelecendo base sólida para desenvolvimentos futuros que possam, com validações adequadas, contribuir efetivamente para a prática clínica.